



CONICET
UNICEN
Universidad Nacional del Centro
de la Provincia de Buenos Aires

Cómo entrenar bien un baseline:

Experiencias y recomendaciones
desde la aplicación de deep learning
en oftalmología

Dr. José Ignacio Orlando

Grupo Yatiris. Instituto PLADEMA / CONICET / UNICEN

@ignaciorlando

José Ignacio Orlando





Inteligencia artificial en medicina



Investigación aplicada

Resolver un problema



Modelo que ya
existe pero nadie usó

Problema nuevo



Modelo que
no existía

Un modelo nuevo!

Un modelo nuevo!

Contribución metodológica al área

¿Cómo lo validamos?

benchmark

protocolo de evaluación
(dataset + métricas)

baselines

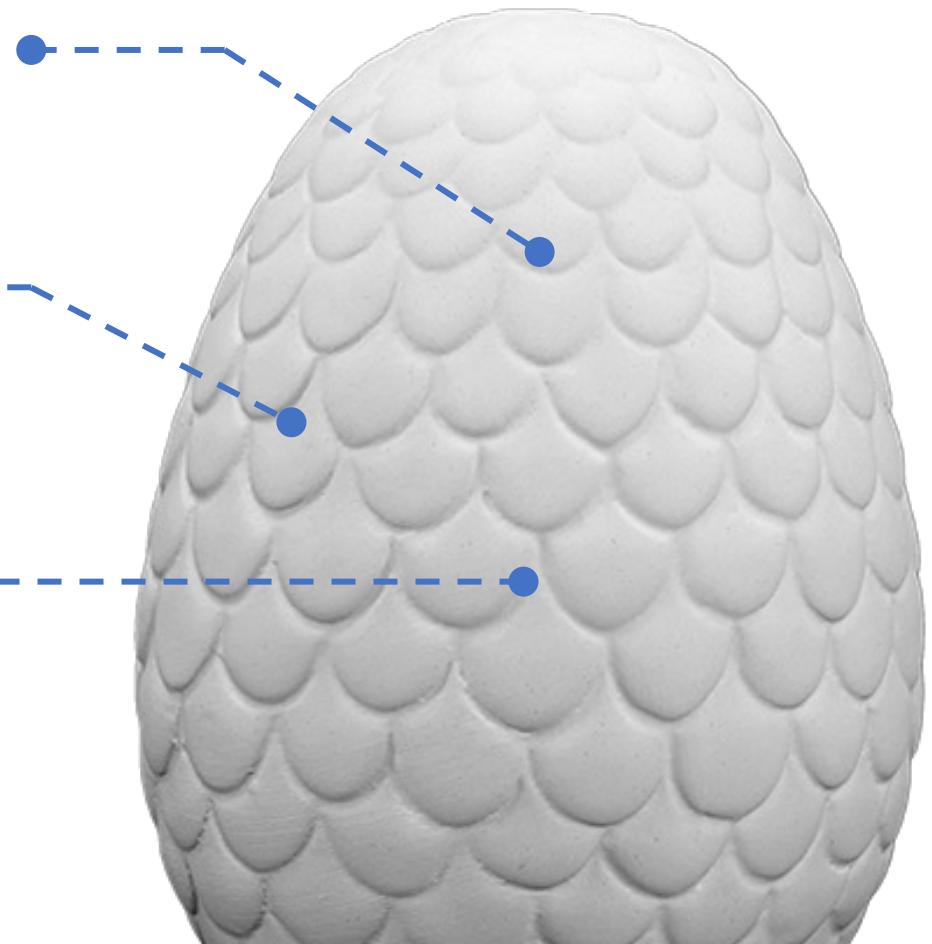
modelos para resolver
un problema similar



El baseline

Adecuado para el problema

Identificar las alternativas que cualquiera usaría



El mejor de todos

Si hay varios, elegimos el que tiene mejores benchmarks

Entrenado con las mismas oportunidades

Misma capacidad, misma cantidad de datos de entrenamiento,
misma rigurosidad en la calibración de hiperparámetros

Image classification

Liu et al. CVPR 2022.

Vision Transformers como estado del arte

O sea que ConvNets nunca más?

Zhuang Liu^{1,2*} Hanzi Mao¹ Chao-Yuan Wu¹ Christoph Feichtenhofer¹ Trevor Darrell² Saining Xie^{1†}

¹Facebook AI Research (FAIR) ²UC Berkeley

Code: <https://github.com/facebookresearch/ConvNeXt>

Abstract

The “Roaring 20s” of visual recognition began with the introduction of Vision Transformers (ViTs), which quickly superseded ConvNets as the state-of-the-art image classification model. A vanilla ViT, on the other hand, faces difficulties when applied to general computer vision tasks such as object detection and semantic segmentation. It is the hierarchical Transformers (e.g., Swin Transformers) that reintroduced several ConvNet priors, making Transformers practically viable as a generic vision backbone and demonstrating remarkable performance on a wide variety of vision tasks. However, the effectiveness of such hybrid approaches is still largely credited to the intrinsic superiority of Transformers, rather than the inherent inductive biases of convolutions. In this work, we reexamine the design spaces and test the limits of what a pure ConvNet can achieve. We gradually “modernize” a standard ResNet toward the design of a vision Transformer, and discover several key components that contribute to the performance difference along the way. The outcome of this exploration is a family of pure ConvNet models dubbed ConvNeXt. Constructed entirely from standard ConvNet modules, ConvNeXts compete favorably with Transformers in terms of accuracy and scalability, achieving 87.8% ImageNet top-1 accuracy and outperforming Swin Transformers on COCO detection and ADE20K segmentation, while maintaining the simplicity and efficiency of standard ConvNets.

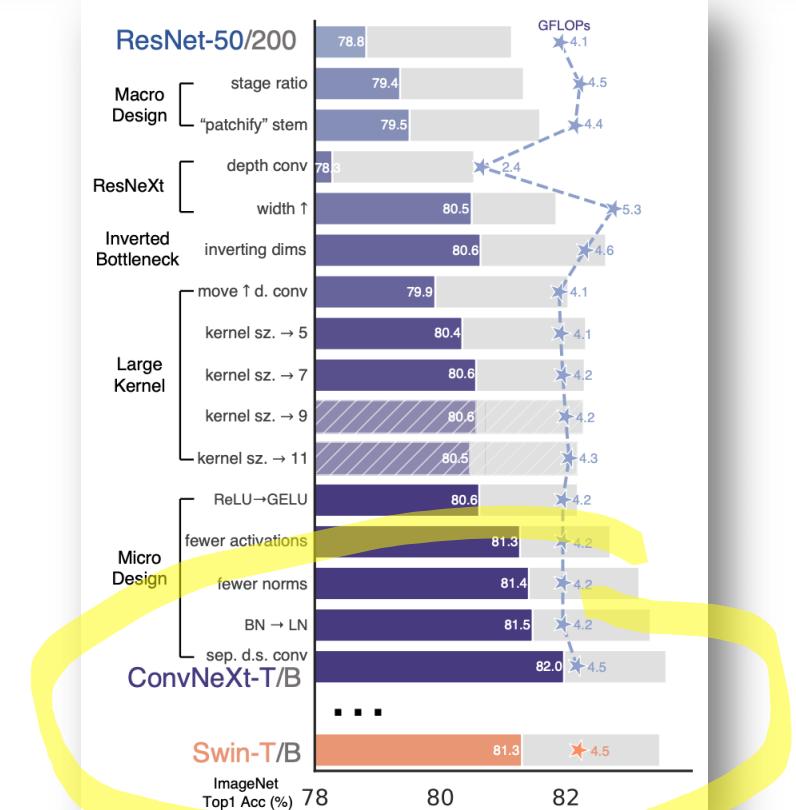


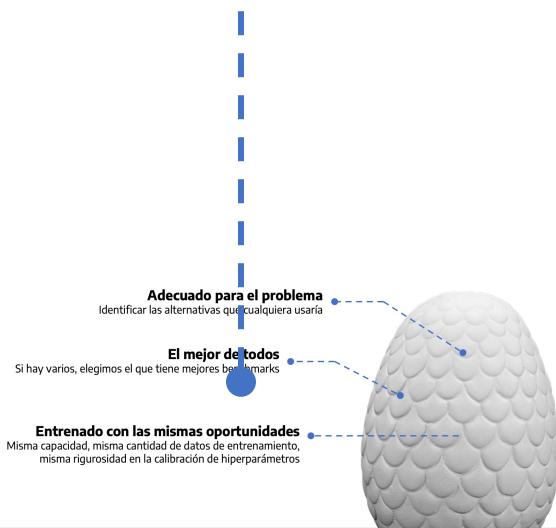
Image classification

Liu et al. CVPR 2022.

Vision Transformers como estado del arte

Realmente tenemos que abandonar las ConvNets?

NO! Hay que armarlas con las mismas herramientas que usan los mejores ViTs!



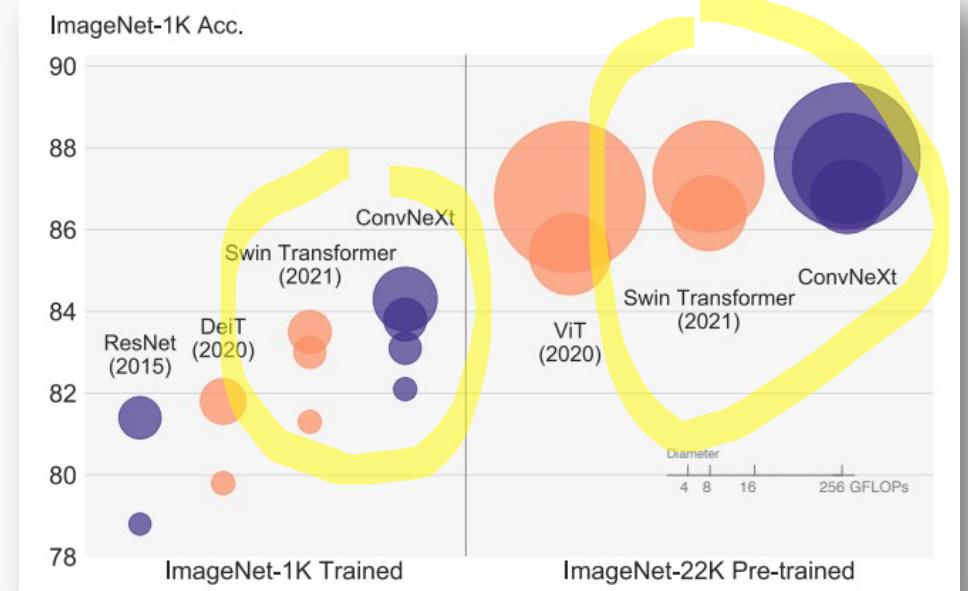
Zhuang Liu^{1,2*} Hanzi Mao¹ Chao-Yuan Wu¹ Christoph Feichtenhofer¹ Trevor Darrell² Saining Xie^{1†}

¹Facebook AI Research (FAIR) ²UC Berkeley

Code: <https://github.com/facebookresearch/ConvNeXt>

Abstract

The “Roaring 20s” of visual recognition began with the introduction of Vision Transformers (ViTs), which quickly superseded ConvNets as the state-of-the-art image classification model. A vanilla ViT, on the other hand, faces difficulties when applied to general computer vision tasks such as object detection and semantic segmentation. It is the hierarchical Transformers (e.g., Swin Transformers) that reintroduced several ConvNet priors, making Transformers practically viable as a generic vision backbone and demonstrating remarkable performance on a wide variety of vision tasks. However, the effectiveness of such hybrid approaches is still largely credited to the intrinsic superiority of Transformers, rather than the inherent inductive biases of convolutions. In this work, we reexamine the design spaces and test the limits of what a pure ConvNet can achieve. We gradually “modernize” a standard ResNet toward the design of a vision Transformer, and discover several key components that contribute to the performance difference along the way. The outcome of this exploration is a family of pure ConvNet models dubbed ConvNeXt. Constructed entirely from standard ConvNet modules, ConvNeXts compete favorably with Transformers in terms of accuracy and scalability, achieving 87.8% ImageNet top-1 accuracy and outperforming Swin Transformers on COCO detection and ADE20K segmentation, while maintaining the simplicity and efficiency of standard ConvNets.





Point cloud shape classification

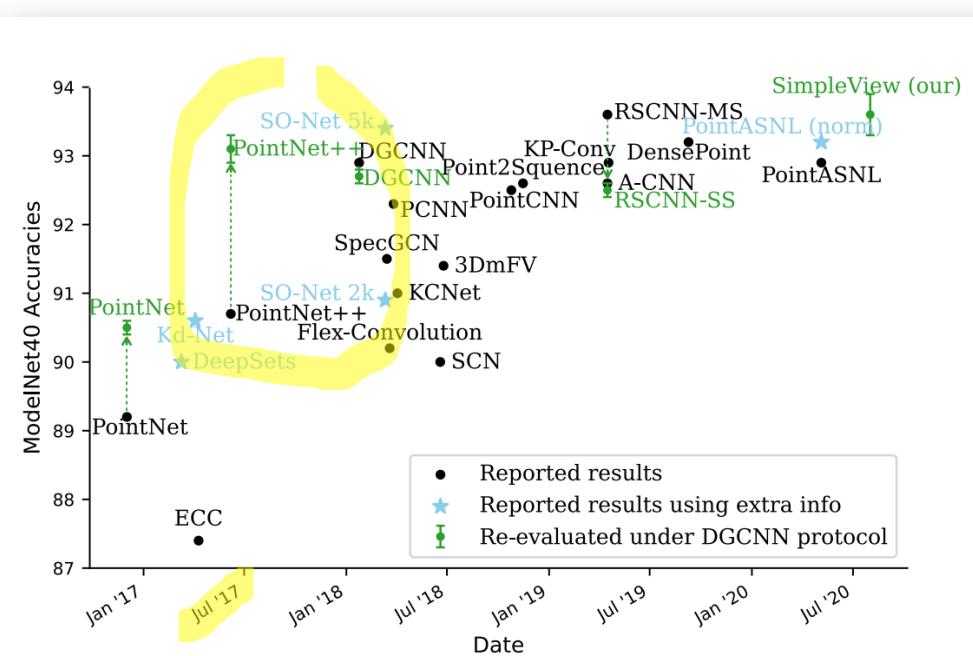
Goyal et al. ICML 2021.

Revisiting Point Cloud Shape Classification with a Simple and Effective Baseline

Ankit Goyal¹ Hei Law¹ Bowei Liu¹ Alejandro Newell¹ Jia Deng¹

Abstract

Processing point cloud data is an important component of many real-world systems. As such, a wide variety of point-based approaches have been proposed, reporting steady benchmark improvements over time. We study the key ingredients of this progress and uncover two critical results. First, we find that auxiliary factors like different evaluation schemes, data augmentation strategies, and loss functions, which are independent of the model architecture, make a large difference in performance. The differences are large enough that they obscure the effect of architecture. When these factors are controlled for, PointNet++, a relatively older network, performs competitively with recent methods. Second, a very simple projection-based method, which we refer to as SimpleView, performs surprisingly well. It achieves on par or better results than sophisticated state-of-the-art methods on ModelNet40 while being half the size of PointNet++. It also outperforms state-of-the-art methods on ScanObjectNN, a real-world point cloud benchmark, and demonstrates better cross-dataset generalization. Code is available at <https://github.com/princeton-vl/SimpleView>.



Muchos modelos diferentes evaluados en el mismo benchmark

**Realmente necesitamos
complejizar más los
modelos?**

NO! Hay que entrenarlos bien!



Point cloud shape classification

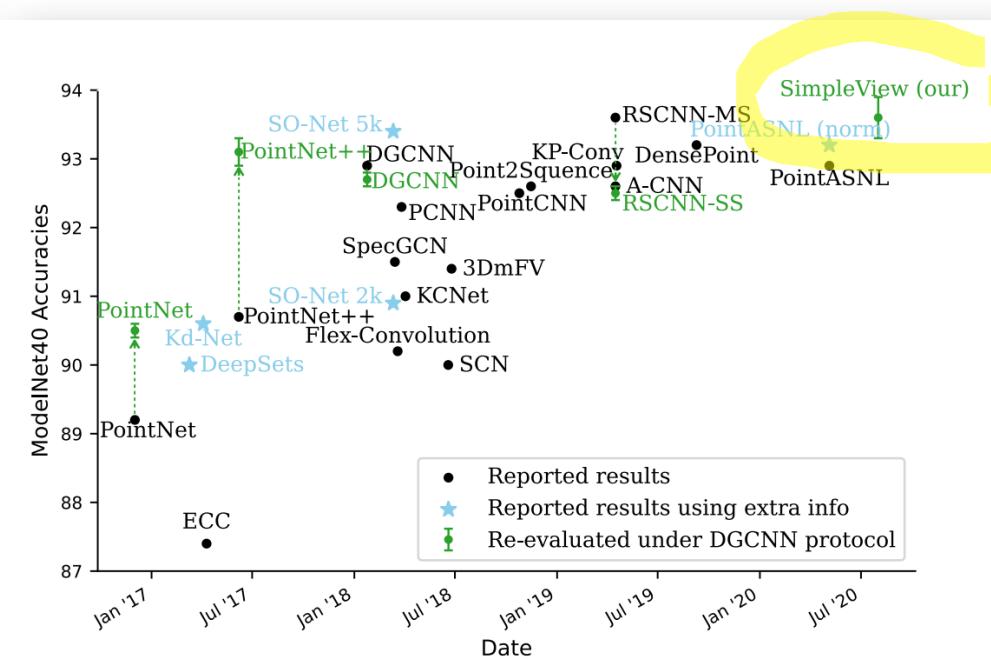
Goyal et al. ICML 2021.

Revisiting Point Cloud Shape Classification with a Simple and Effective Baseline

Ankit Goyal¹ Hei Law¹ Bowei Liu¹ Alejandro Newell¹ Jia Deng¹

Abstract

Processing point cloud data is an important component of many real-world systems. As such, a wide variety of point-based approaches have been proposed, reporting steady benchmark improvements over time. We study the key ingredients of this progress and uncover two critical results. First, we find that auxiliary factors like different evaluation schemes, data augmentation strategies, and loss functions, which are independent of the model architecture, make a large difference in performance. The differences are large enough that they obscure the effect of architecture. When these factors are controlled for, PointNet++, a relatively older network, performs competitively with recent methods. Second, a very simple projection-based method, which we refer to as SimpleView, performs surprisingly well. It achieves on par or better results than sophisticated state-of-the-art methods on ModelNet40 while being half the size of PointNet++. It also outperforms state-of-the-art methods on ScanObjectNN, a real-world point cloud benchmark, and demonstrates better cross-dataset generalization. Code is available at <https://github.com/princeton-vl/SimpleView>.



Muchos modelos diferentes evaluados en el mismo benchmark

Realmente necesitamos complejizar más los modelos?

NO! Hay que entrenarlos bien!

Modelos simples que funcionan mejor que modelos más complejos!

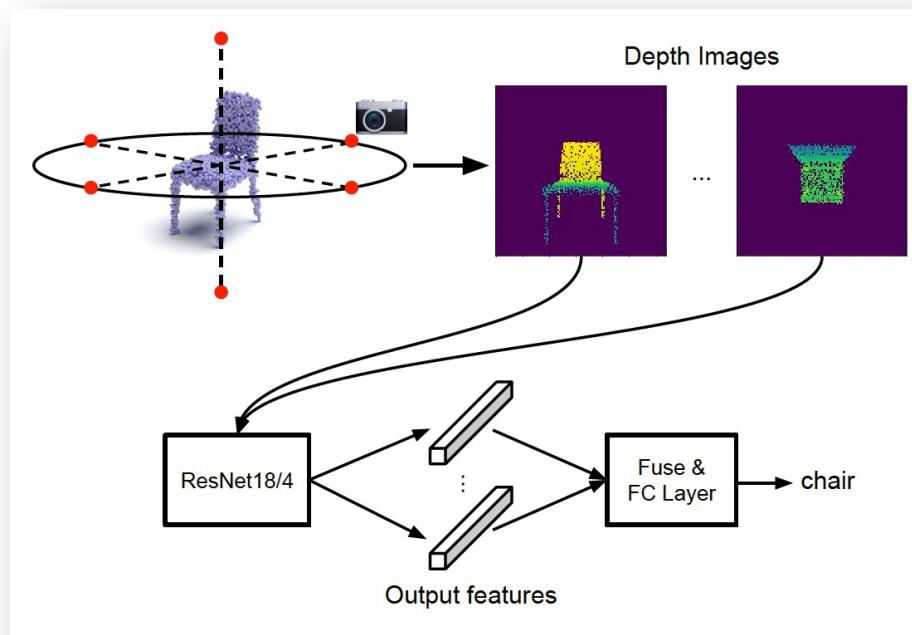


Revisiting Point Cloud Shape Classification with a Simple and Effective Baseline

Ankit Goyal¹ Hei Law¹ Bowei Liu¹ Alejandro Newell¹ Jia Deng¹

Abstract

Processing point cloud data is an important component of many real-world systems. As such, a wide variety of point-based approaches have been proposed, reporting steady benchmark improvements over time. We study the key ingredients of this progress and uncover two critical results. First, we find that auxiliary factors like different evaluation schemes, data augmentation strategies, and loss functions, which are independent of the model architecture, make a large difference in performance. The differences are large enough that they obscure the effect of architecture. When these factors are controlled for, PointNet++, a relatively older network, performs competitively with recent methods. Second, a very simple projection-based method, which we refer to as SimpleView, performs surprisingly well. It achieves on par or better results than sophisticated state-of-the-art methods on ModelNet40 while being half the size of PointNet++. It also outperforms state-of-the-art methods on ScanObjectNN, a real-world point cloud benchmark, and demonstrates better cross-dataset generalization. Code is available at <https://github.com/princeton-vl/SimpleView>.



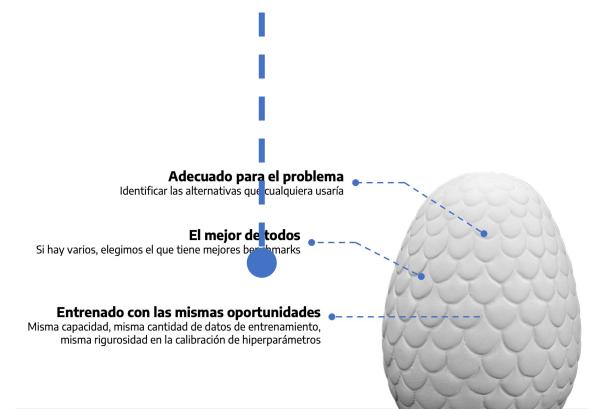
Point cloud
shape classification
Goyal et al. ICML 2021.

Muchos modelos diferentes
evaluados en el mismo benchmark

**Realmente necesitamos
complejizar más los
modelos?**

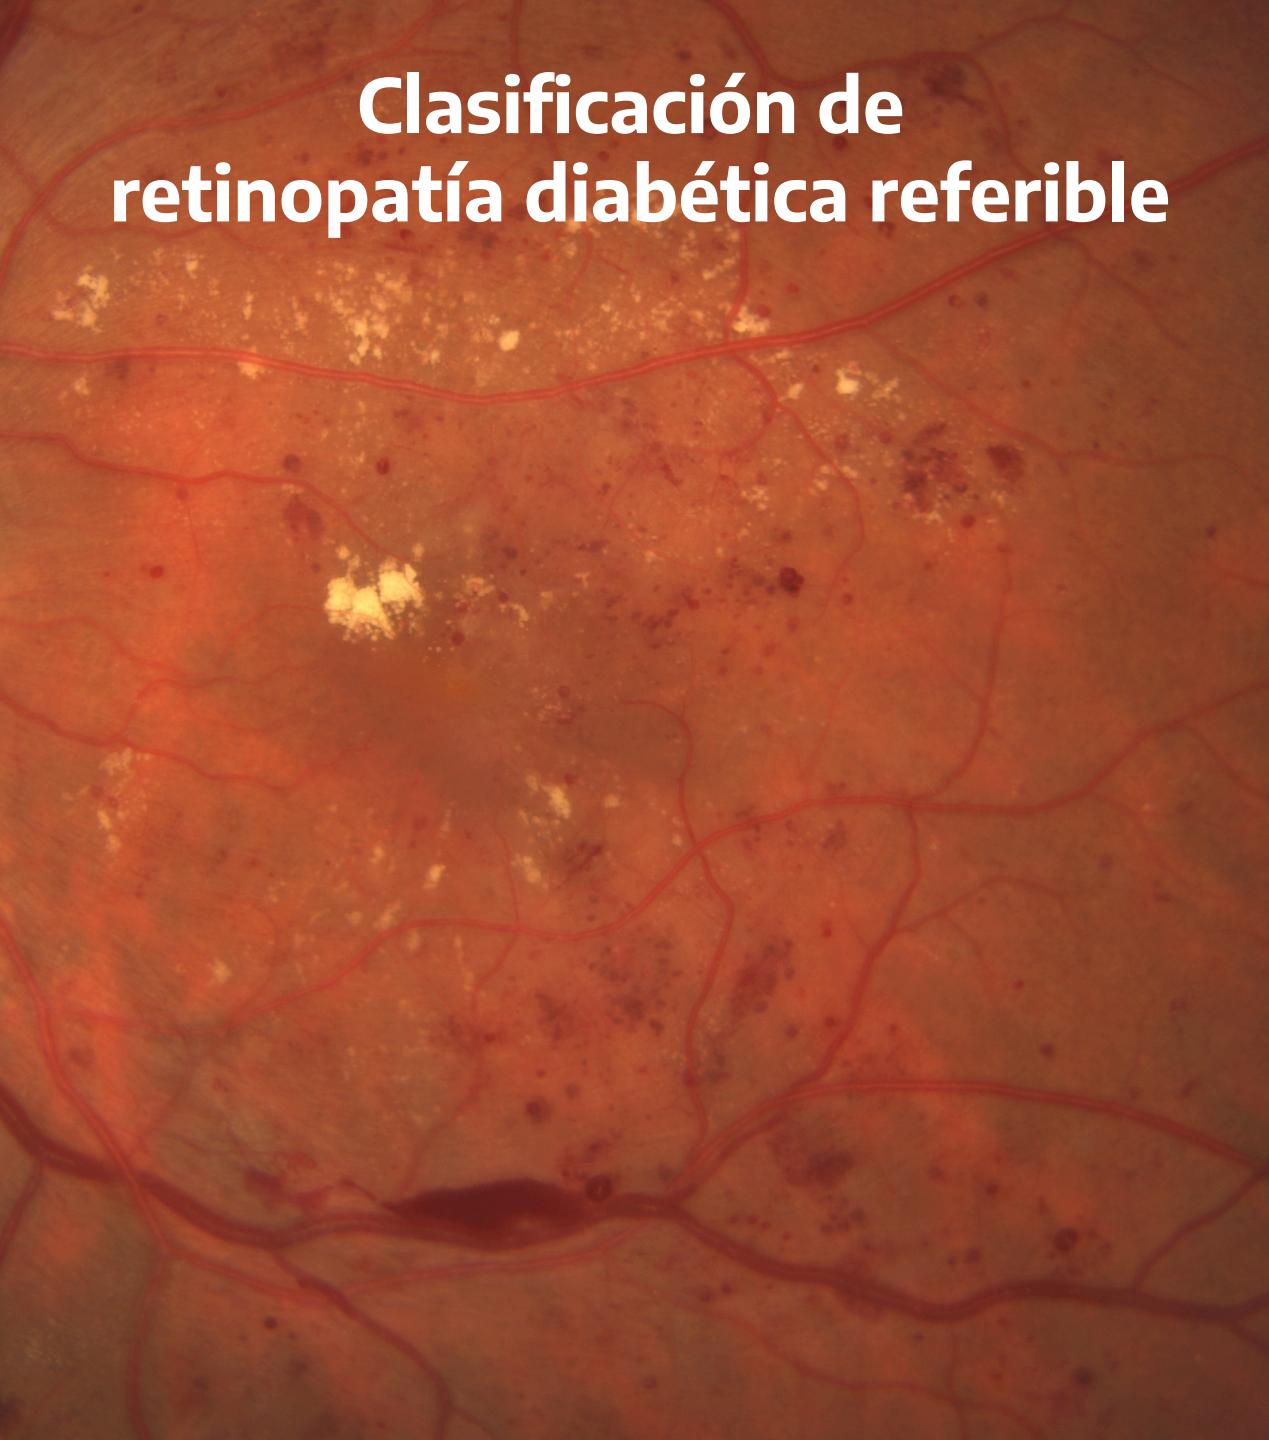
NO! Hay que entrenarlos bien!

**Modelos simples que funcionan
mejor que modelos más complejos!**



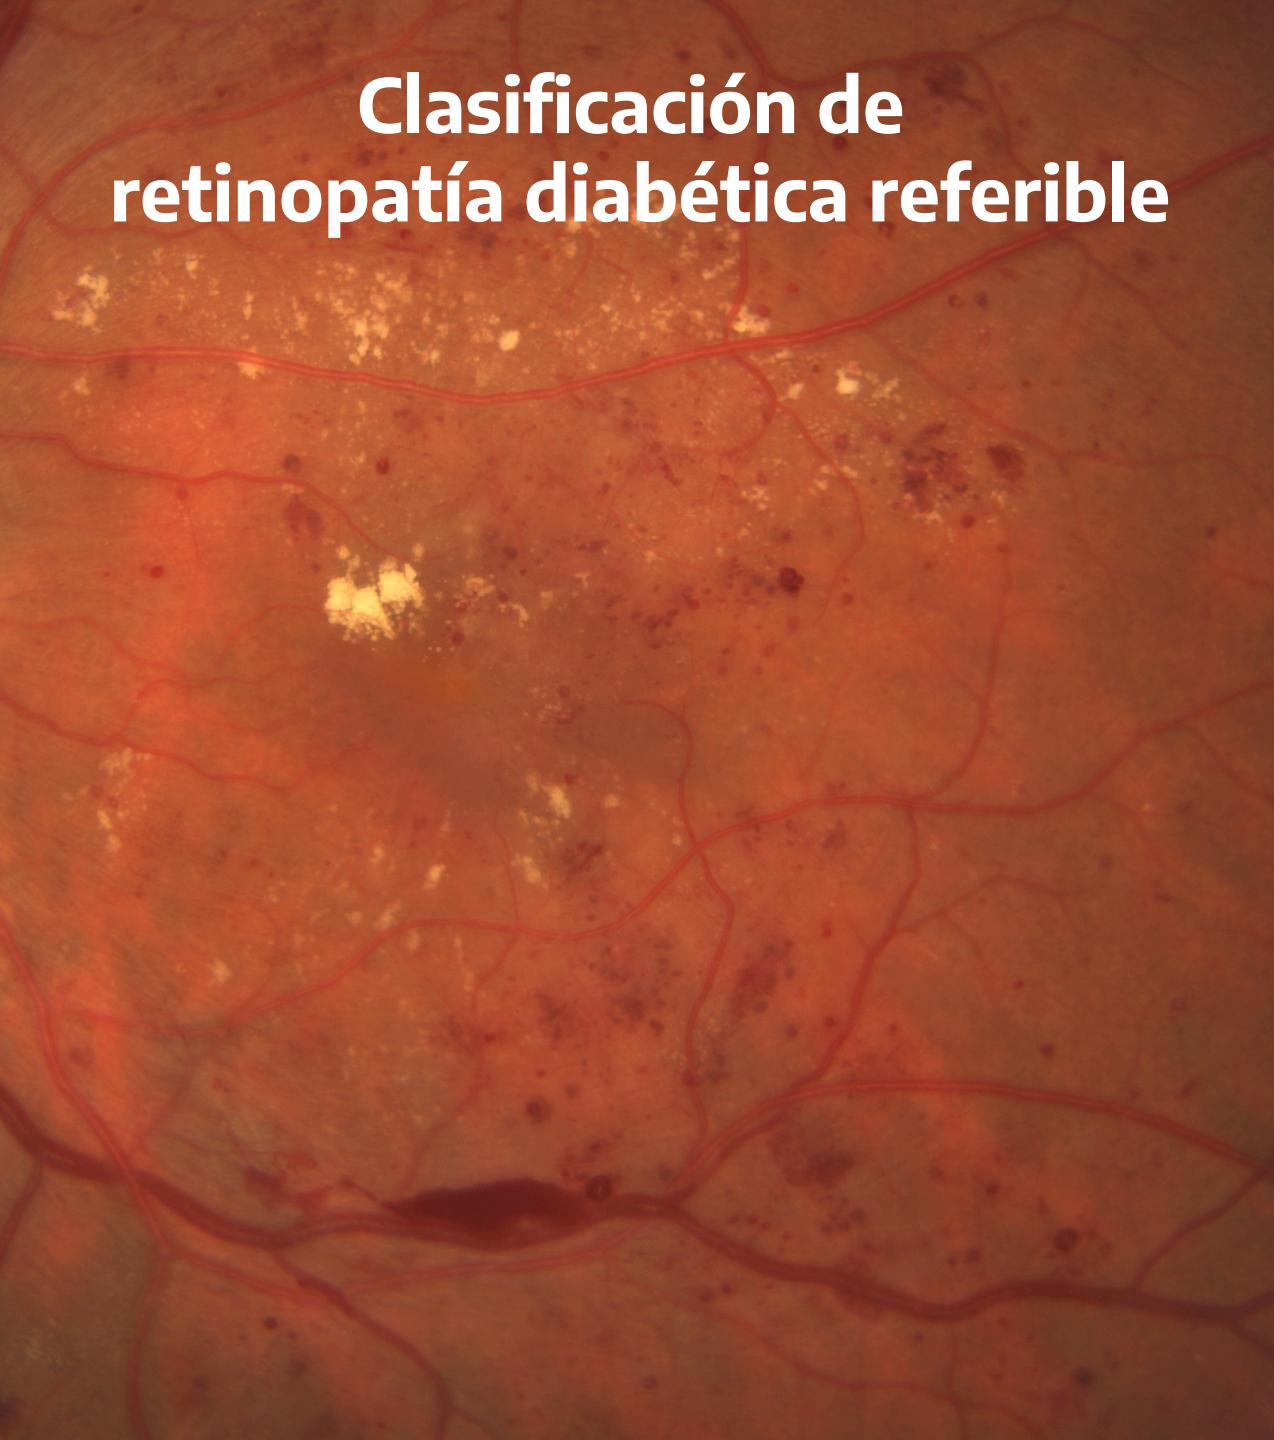
¿Qué pasa en aplicaciones médicas?

Clasificación de retinopatía diabética referible



Segmentación de
disco/copa óptica en glaucoma

Clasificación de retinopatía diabética referible



Segmentación de
disco/copa óptica en glaucoma



Clasificación de retinopatía diabética referible

- **Problema binario de clasificación**

No referible (clase 0) y referible (clase 1)

- **Múltiples datasets públicos disponibles**

Más de 100.000 imágenes etiquetadas en diferentes conjuntos

- **Benchmarks específicos**

Challenges diseñados con sus propios datos y métricas

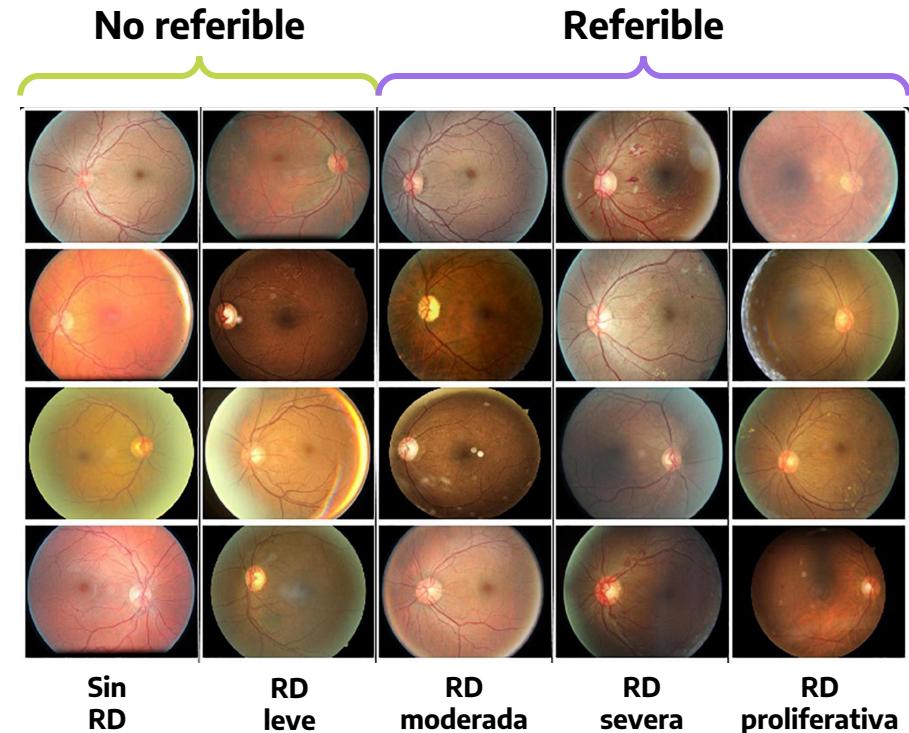
- **Protocolos de evaluación diversos**

Al publicarse los datos, dejan de respetarse los criterios aplicados

- **Muchos métodos diferentes**

Revistas médicas → Modelos básicos

Revistas técnicas → Métodos complejos



- **Entrenemos un baseline**

Clasificación de retinopatía diabética referible

• (1) Identificamos todas las bases públicas con etiquetas de referibilidad

Particiones

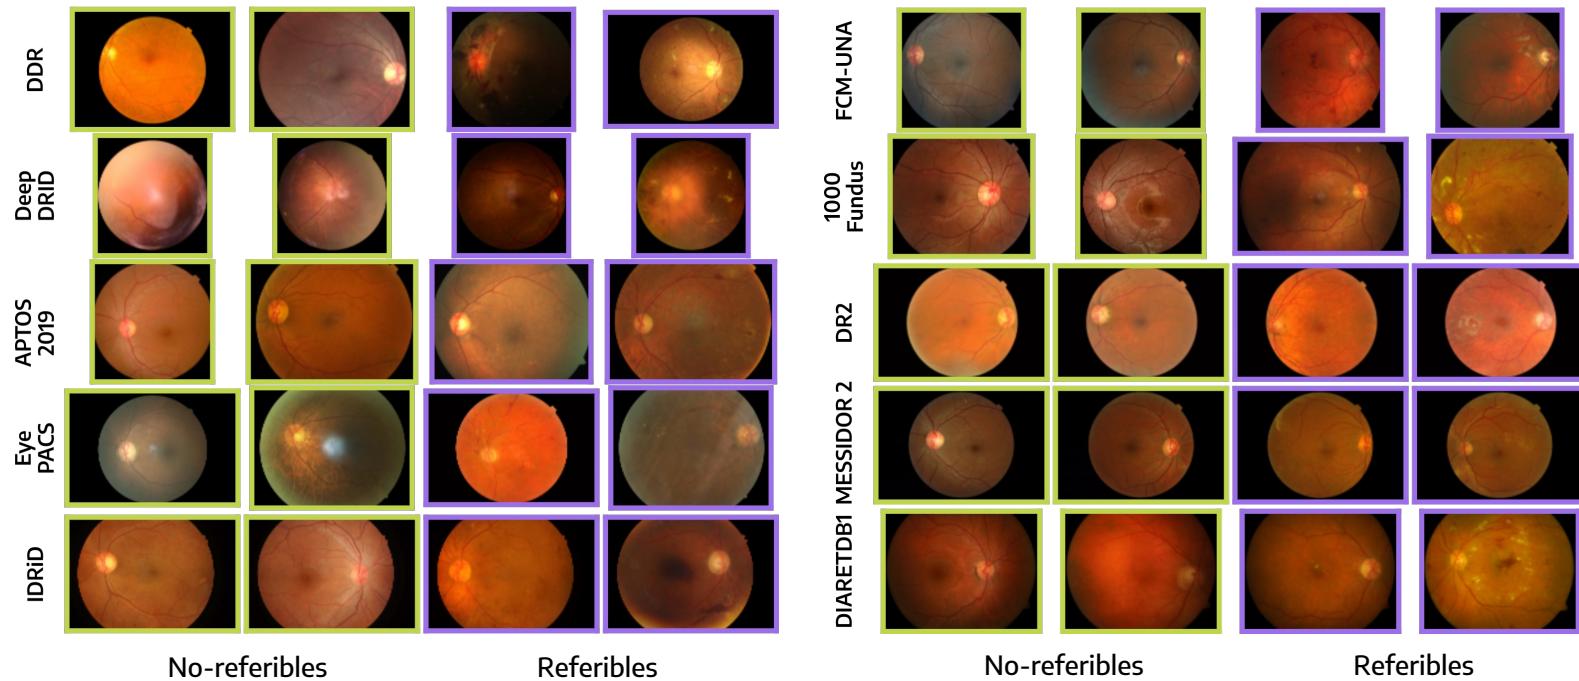
¿Ya están divididas?
¿Qué patrones de uso sigue la literatura?

Imágenes

¿Qué resolución tienen?
¿Qué cámaras se utilizan?
¿Qué ángulo de FOV?
¿Midriática o no midriática?
¿Qué étnias específicas fueron escaneadas?

Etiquetas

¿Grados? ¿Binarias?



Clasificación de retinopatía diabética referible

--- ● (1) Identificamos todas las bases públicas con etiquetas de referibilidad

Particiones

¿Ya están divididas?
¿Qué patrones de uso sigue la literatura?

Imágenes

¿Qué resolución tienen?
¿Qué cámaras se utilizan?
¿Qué ángulo de FOV?
¿Midriática o no midriática?
¿Qué étnias específicas fueron escaneadas?

Etiquetas

¿Grados? ¿Binarias?

Dataset	Num. samples			Training	Validation	Test
	Non-referable DR	Referable DR	Total			
APOTOS2019 *	2175	1487	3662	3662	0	0
DeepDRID ²⁹	900	700	1600	1200	0	400
DDR ⁸	6896	5626	12522	6260	2503	3759
EyePACS †	71548	17154	88702	28098	7026	53576
IDRiD ²⁸	193	323	516	372	40	103
FCM-UNA ³⁰	191	566	757	0	0	757
1000Fundus ³¹	56	88	144	0	0	144
DR2 ⁴	337	98	435	0	0	435
MESSIDOR 2 ²⁷	1287	457	1744	0	0	1744
DIARETDB1 ³²	43	46	89	0	0	89
Martínez (private)	454	30	484	0	0	484
HEC (private)	26	9	35	0	0	35
Total	89433	27735	117168	39592	9569	61526

Castilla, T. Martínez, M. S. Leguía, M. Larrabide, I. and Orlando, J I.

"A ResNet is All You Need? Modeling A Strong Baseline for Detecting Referable Diabetic Retinopathy in Fundus Images"

18th International Symposium on Medical Information Processing and Analysis (SIPAIM 2022).

Clasificación de retinopatía diabética referible

● (2) Preprocesamiento para integrar estudios de diferentes conjuntos

● Recorte automático del FOV

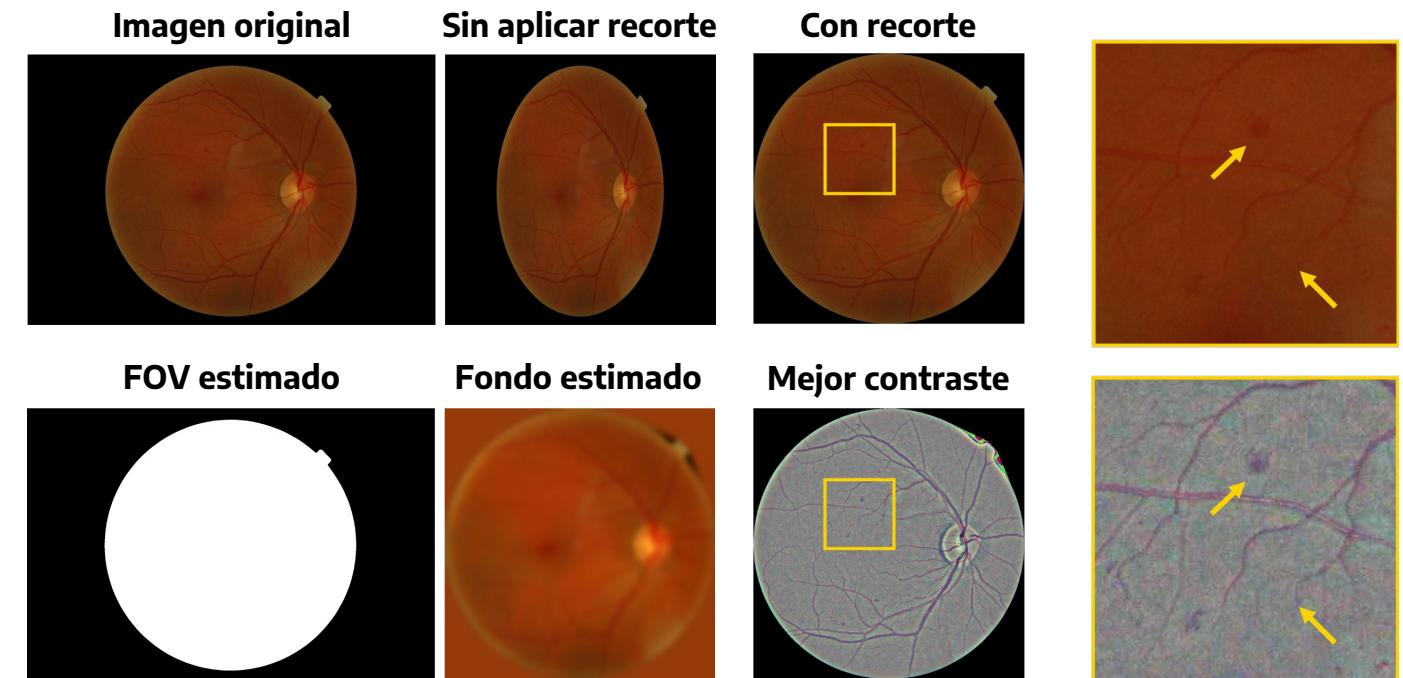
Para evitar deformar las imágenes con artefactos poco realistas

● Mejora de contraste

Para mejorar la identificación de las lesiones típicas de la RD

● Resolución 512 x 512 px

Para evitar la desaparición de lesiones muy pequeñas

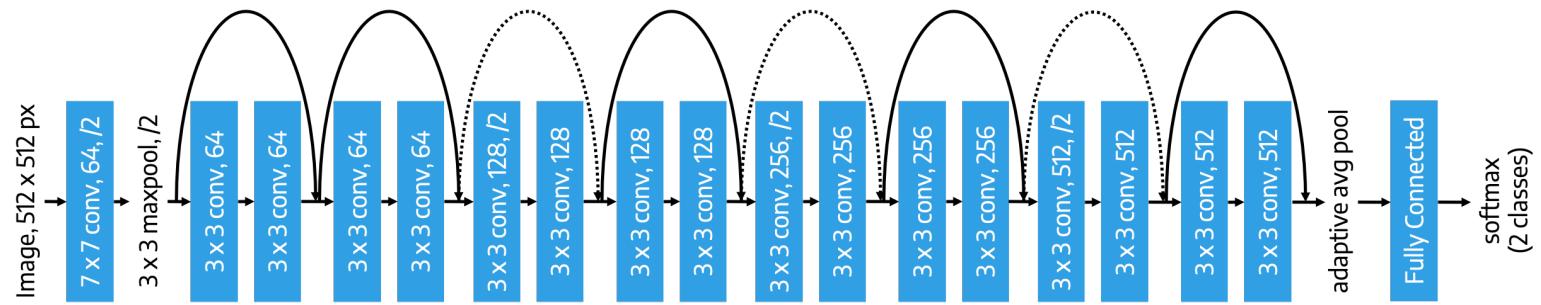


Clasificación de retinopatía diabética referible

● (3) Entrenamiento de un modelo simple aplicando buenas prácticas

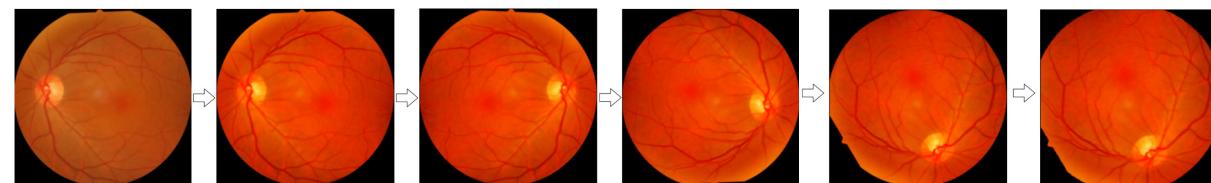
ResNet18

Pre-entrenada en ImageNet
Adaptada para clasificación binaria
Fine-tuning



Ajuste incremental del data augmentation

Forward selection de los parámetros de las estrategias de data augmentation



Clasificación de retinopatía diabética referible

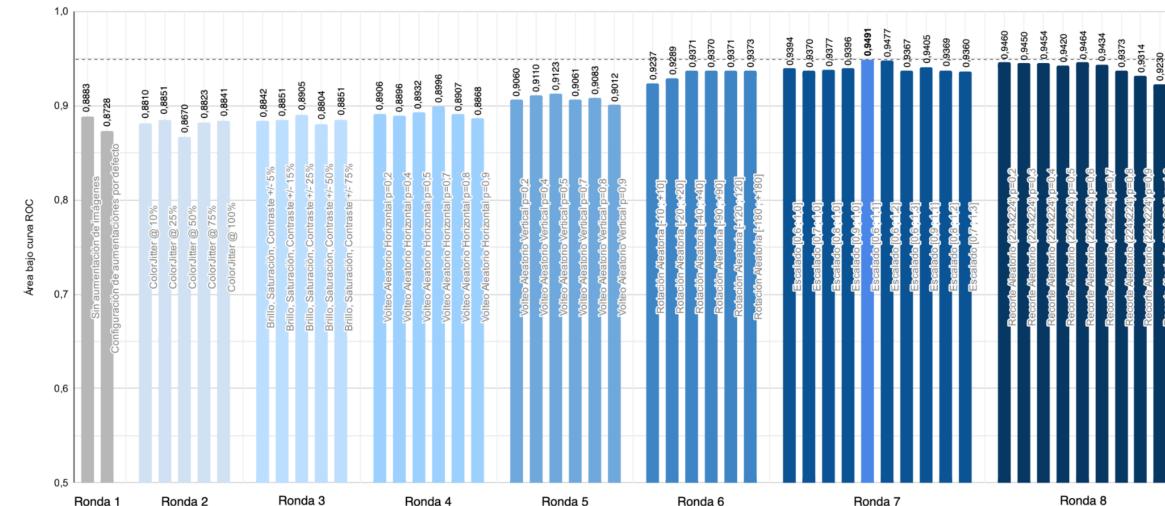
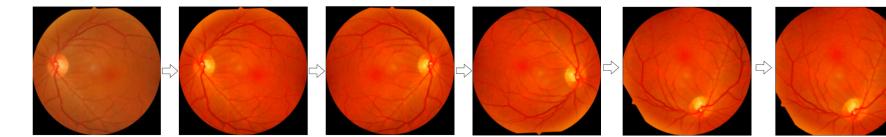
● (3) Entrenamiento de un modelo simple aplicando buenas prácticas

ResNet18

Pre-entrenada en Image-Net
Adaptada para clasificación binaria
Fine-tuning

Ajuste incremental del data augmentation

Forward selection de los parámetros de las estrategias de data augmentation



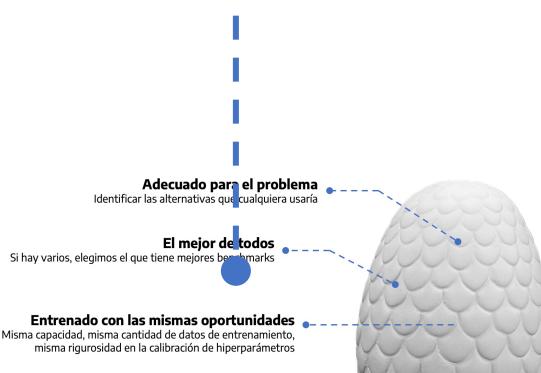
Clasificación de retinopatía diabética referible

● (4) Evaluación sobre conjuntos y particiones estándar de la literatura + datos propios

Valores iguales o superiores a los de la literatura

Comparado con trabajos evaluados con iguales métricas y en iguales conjuntos

Modelo simple + datos + preprocesamiento



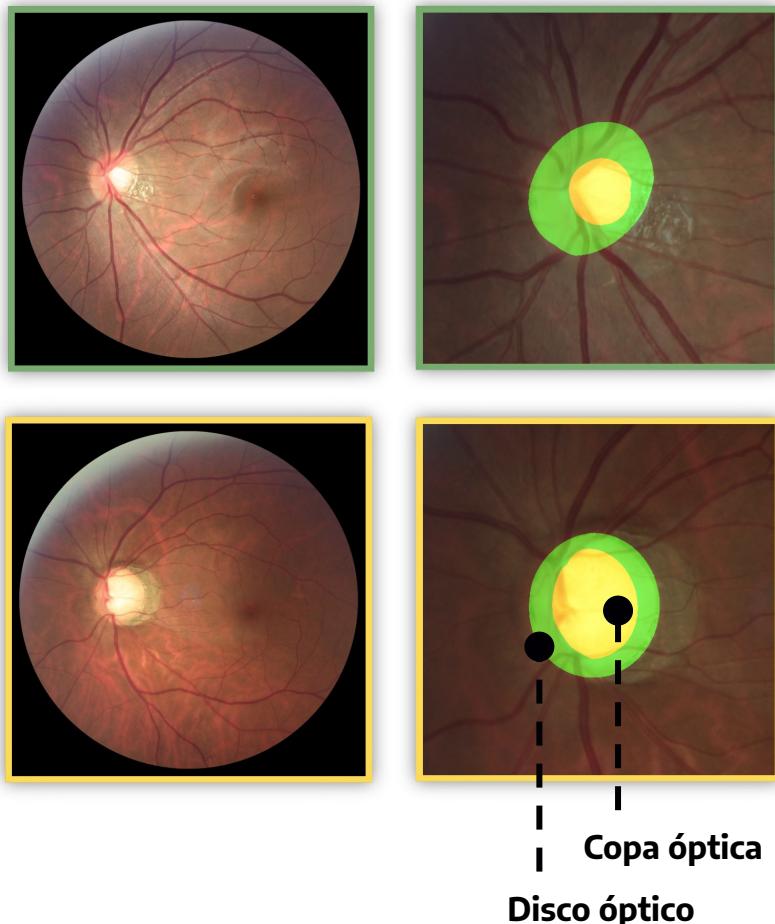
Per-image referable DR classification				
Test dataset	Method	AUC (95% CI)	Se (95% CI)	Sp (95% CI)
1000Fundus	ResNet-18 (ours)	1.000 (1.000 - 1.000)	1.000 (0.958 - 1.000)	0.982 (0.906 - 0.997)
	Zago <i>et al.</i> 2020 ¹⁰	0.833 (0.819 - 0.846)	-	-
DDR	ResNet-18 (ours)	0.965 (0.960 - 0.970)	0.749 (0.728 - 0.769)	0.978 (0.971 - 0.984)
	DeepDRID	0.959 (0.944 - 0.972)	0.883 (0.828 - 0.922)	0.868 (0.817 - 0.907)
DIARETDB1	ResNet-18 (ours)	0.981 (0.956 - 0.999)	0.957 (0.855 - 0.988)	0.930 (0.814 - 0.976)
	DR2	Pires <i>et al.</i> 2019 ¹⁵	0.963 (0.938 - 0.981)	-
EyePACS	ResNet-18 (ours)	0.974 (0.962 - 0.985)	0.847 (0.763 - 0.905)	0.961 (0.935 - 0.977)
	Quellec <i>et al.</i> 2017 ⁷	0.944	-	-
FCM-UNA	Pires <i>et al.</i> 2019 ¹⁵	0.946	-	-
	ResNet-18 (ours)	0.951 (0.949 - 0.954)	0.732 (0.723 - 0.740)	0.979 (0.978 - 0.980)
IDRiD	ResNet-18 (ours)	0.986 (0.980 - 0.992)	0.882 (0.852 - 0.906)	0.990 (0.963 - 0.997)
	Zago <i>et al.</i> 2020 ¹⁰	0.796 (0.715 - 0.892)	-	-
MESSIDOR 2	Hervella <i>et al.</i> 2022 ¹²	0.944	-	-
	ResNet-18 (ours)	0.949 (0.914 - 0.980)	0.828 (0.718 - 0.901)	0.897 (0.764 - 0.959)
HEC	Gulshan <i>et al.</i> 2016 ³	0.990 (0.986 - 0.995)	0.961 (0.924 - 0.983)	0.939 (0.924 - 0.953)
	Gargaya <i>et al.</i> 2017 ⁶	0.940	0.930	0.870
Martínez	Voets <i>et al.</i> 2019 ³³	0.853 (0.835 - 0.871)	0.818	0.687
	Zago <i>et al.</i> 2020 ¹⁰	0.944 (0.925 - 0.966)	0.900 (0.860 - 0.961)	0.870 (0.863 - 0.871)
Li <i>et al.</i> 2022 ¹⁹	Li <i>et al.</i> 2022 ¹⁹	0.977 (0.974 - 0.981)	0.923 (0.917 - 0.925)	0.947 (0.937 - 0.954)
	ResNet-18 (ours)	0.973 (0.967 - 0.979)	0.895 (0.863 - 0.920)	0.941 (0.927 - 0.953)
Castilla, T. Martínez, M. S. Leguía, M. Larrabide, I. and Orlando, J I. "A ResNet is All You Need? Modeling A Strong Baseline for Detecting Referable Diabetic Retinopathy in Fundus Images" 18th International Symposium on Medical Information Processing and Analysis (SIPAIM 2022).				

Clasificación de retinopatía diabética referible



Segmentación de disco/copa óptica en glaucoma

- **Problema multiclas/multilabel de segmentación**
Disco óptico (clase 1), copa óptica (clase 2) y fondo (clase 0)
- **Múltiples datasets públicos disponibles**
Más de 3.400 imágenes segmentadas en diferentes conjuntos
- **Benchmarks específicos**
Challenges diseñados con sus propios datos y métricas
- **Protocolos de evaluación diversos**
Al publicarse los datos, dejan de respetarse los criterios aplicados
- **Muchos métodos diferentes**
Revistas médicas → Modelos básicos
Revistas técnicas → Métodos complejos
- **Entrenemos un baseline**

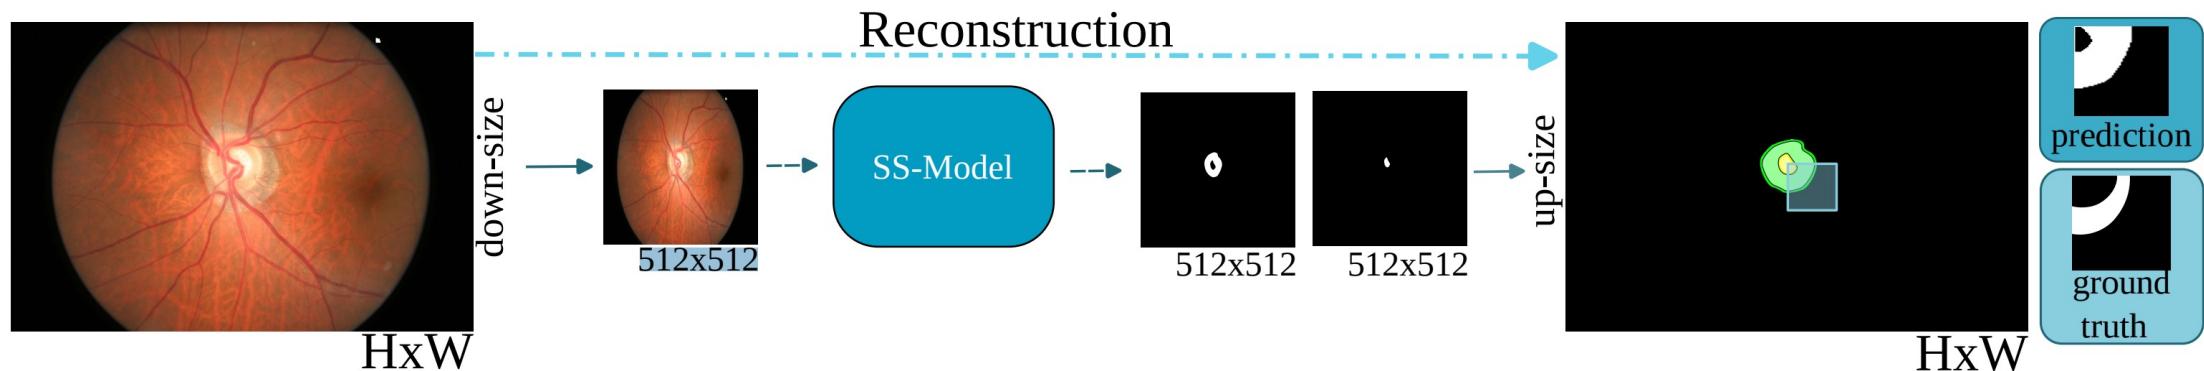


Segmentación de disco/copa óptica en glaucoma

• Entrenemos un baseline • ¿Cuál?

Una única etapa (Single Stage, SS)

U-Net multiclase estándar

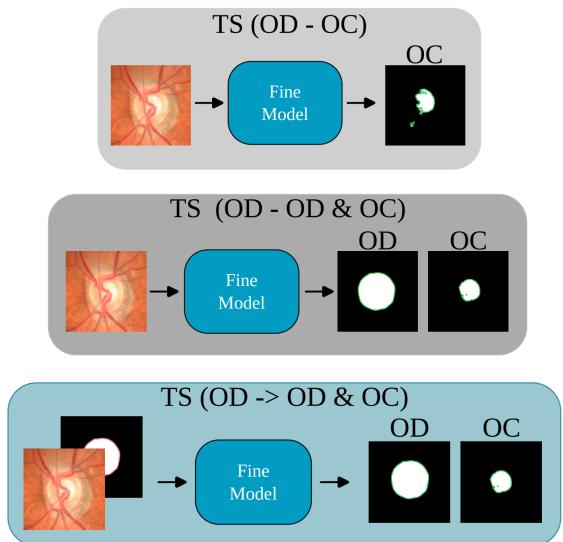
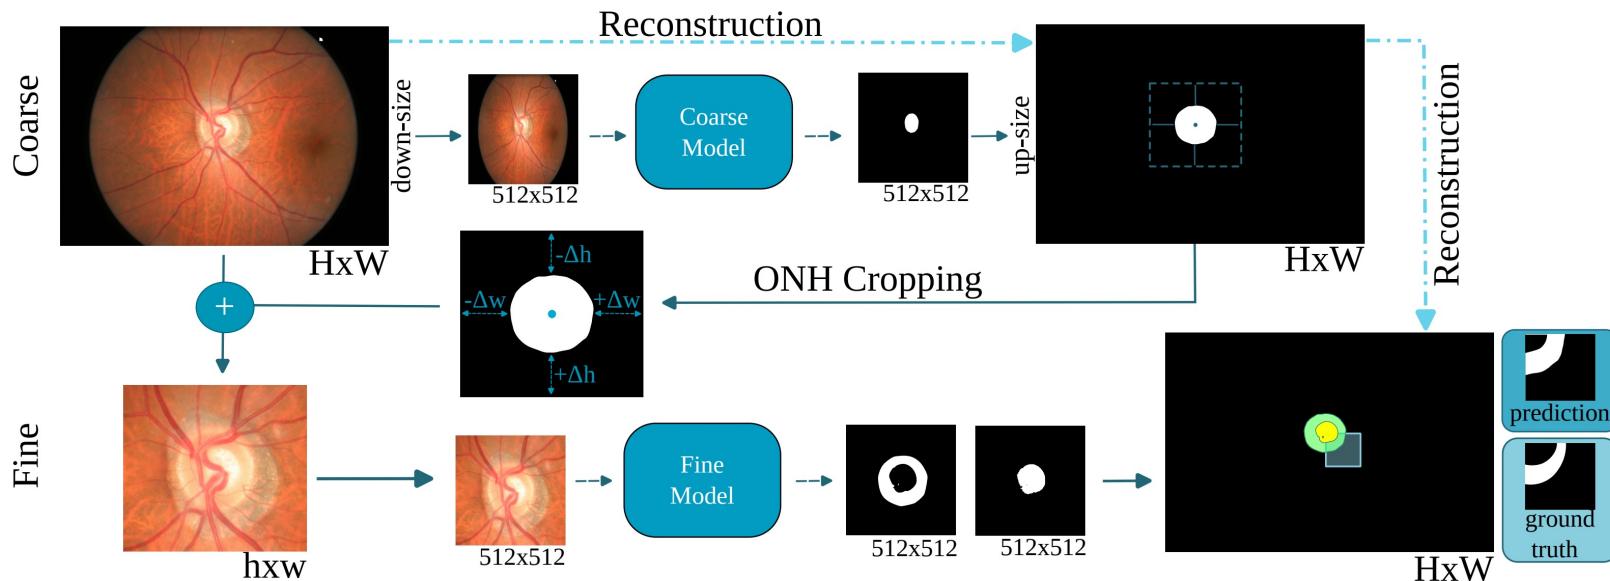


Segmentación de disco/copa óptica en glaucoma

• Entrenemos un baseline • ¿Cuál?

Dos etapas (Coarse-to-Fine, TS)

Dos U-Nets, una que segmenta OD en baja resolución y otra que segmenta OD/OC en alta resolución

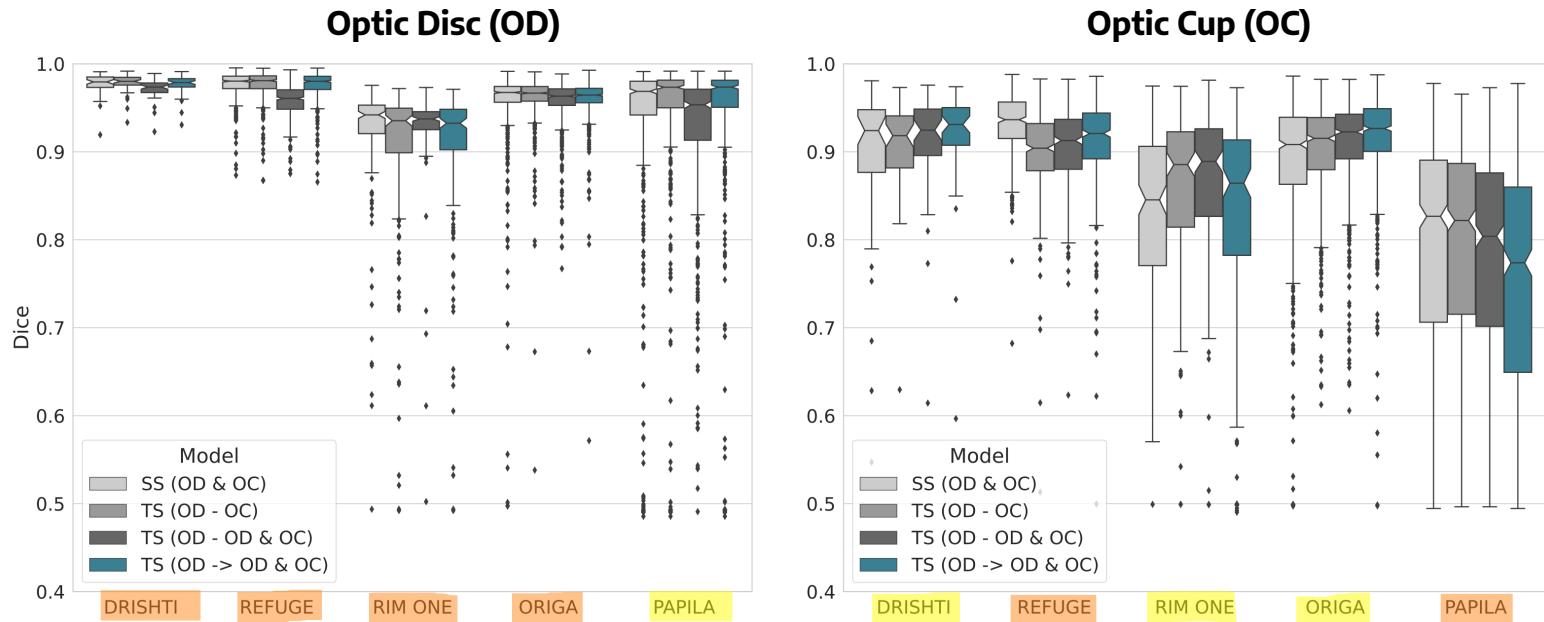


Segmentación de disco/copa óptica en glaucoma

● Evaluación sobre conjuntos y particiones estándar de la literatura

● No necesariamente las dos etapas ayudan

Independientemente del diseño específico que usemos de la conexión entre etapas



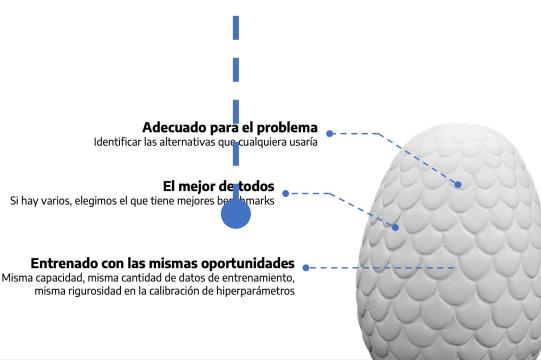
Segmentación de disco/copa óptica en glaucoma

● Evaluación sobre conjuntos y particiones estándar de la literatura

No necesariamente las dos etapas ayudan

Independientemente del diseño específico que usemos de la conexión entre etapas

Algunos modelos SS son mejores o iguales que el estado del arte!



Method	Optic disc (OD) segmentation				Optic cup (OC) segmentation			
	REFUGE	DRISHTI	RIM ONE v3	ORIGA	REFUGE	DRISHTI	RIM ONE v3	ORIGA
Al-Bandet <i>et al.</i> (2018) ¹¹	-	0.949	0.904	0.965	-	0.828	0.690	0.866
Team CUHKMED (REFUGE, 2019) ¹	0.960	-	-	-	0.883	-	-	-
Team Masker (REFUGE, 2019) ¹	0.946	-	-	-	0.884	-	-	-
Team BUCT (REFUGE, 2019) ¹	0.953	-	-	-	0.873	-	-	-
Wang <i>et al.</i> (2019) ⁹	0.960	0.965	0.865	-	0.883	0.858	0.787	-
Shah <i>et al.</i> (2019) ⁸	-	0.960	0.940	-	-	0.890	0.820	-
Tabassum <i>et al.</i> (2020) ¹⁰	-	0.959	0.958	-	-	0.924	0.862	-
Liu <i>et al.</i> (2021) ⁷	0.960	0.978	-	-	0.890	0.912	-	-
He <i>et al.</i> (2022) ¹⁹	0.954	-	-	-	0.869	-	-	-
SS-model (REFUGE)	0.971 ± 0.015	0.957 ± 0.039	0.841 ± 0.130	0.909 ± 0.123	0.922 ± 0.033	0.899 ± 0.064	0.773 ± 0.131	0.874 ± 0.119
TS (OD → OD&OC) (REFUGE)	0.974 ± 0.014	0.966 ± 0.024	0.830 ± 0.134	0.894 ± 0.140	0.879 ± 0.071	0.901 ± 0.063	0.740 ± 0.168	0.851 ± 0.154
SS-model (DRISHTI)	0.881 ± 0.122	0.969 ± 0.025	0.911 ± 0.065	0.837 ± 0.186	0.795 ± 0.123	0.899 ± 0.073	0.764 ± 0.118	0.778 ± 0.165
TS (OD → OD&OC) (DRISHTI)	0.917 ± 0.084	0.973 ± 0.018	0.822 ± 0.059	0.880 ± 0.159	0.801 ± 0.131	0.899 ± 0.082	0.787 ± 0.121	0.809 ± 0.163
SS-model (multi-dataset)	0.976 ± 0.016	0.977 ± 0.012	0.919 ± 0.072	0.956 ± 0.049	0.931 ± 0.035	0.895 ± 0.090	0.829 ± 0.099	0.890 ± 0.079
TS (OD → OD&OC) (multi-dataset)	0.976 ± 0.017	0.977 ± 0.011	0.898 ± 0.094	0.959 ± 0.028	0.910 ± 0.055	0.917 ± 0.063	0.820 ± 0.136	0.915 ± 0.056



¿Cómo entrenar bien a tu baseline?

¿Nuestra receta?



¡La misma que deberías aplicar a tu modelo!

Los datos



- **Reunir la mayor cantidad de datos posibles**
Mejor uso de la capacidad del modelo (large-scale era)
- **Establecer un criterio de integración de datos**
No mezclarlos así nomás!
- **Generar un buen conjunto de validación**
Para asegurar la efectividad del ajuste de hiperparámetros
- **Plantear conjuntos de test para evaluar diferentes escenarios**
Recordar estudiar sesgos en los resultados!
- **Vas a publicar?**

Entrená/evaluá también los baselines en las benchmarks
Respetando iguales particiones de entrenamiento / validación / test (más experimentos, sí!)

Publicá las particiones que creaste a partir de datos públicos
Para que otras personas puedan reproducir tus mismos experimentos

El entrenamiento

---- • 1. Lograr overfitting

Sí o sí la loss de entrenamiento a (casi) 0

Si no puedo llegar, tengo underfitting → mi baseline está mal entrenado

---- • Buscar mejor combinación de learning rate + optimizador

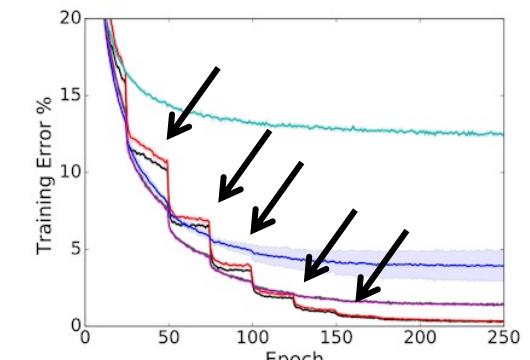
Tabular combinaciones learning rate + optimizador vs. performance

---- • ¿Necesito un learning rate scheduler?

Si veo convergencia en la curva de aprendizaje muy lejos de cero, probar!

---- • ¿Necesito más capacidad?

Si learning rate + optimizador + scheduler no alcanzan, probablemente...



El entrenamiento

----● 1. Lograr overfitting

Sí o sí la loss de entrenamiento a (casi) 0

Si no puedo llegar, tengo underfitting → mi baseline está mal entrenado

----● Buscar mejor combinación de learning rate + optimizador

Tabular combinaciones learning rate + optimizador vs. performance

----● ¿Necesito un learning rate scheduler?

Si veo convergencia en la curva de aprendizaje muy lejos de cero, probar!

----● ¿Necesito más capacidad?

Si learning rate + optimizador + scheduler no alcanzan, probablemente

**Evaluar en
training y validation set**

No regularizar todavía!!

El entrenamiento

2. Reducir el overfitting

Ahora lo queremos bajar...
... pero sin romper todo

Ordenar qué políticas de data augmentation

Definir operaciones + estrategia tipo RandAugment
(nro. operaciones vs. fuerza)

Weight decay?

Probar algunas tasas

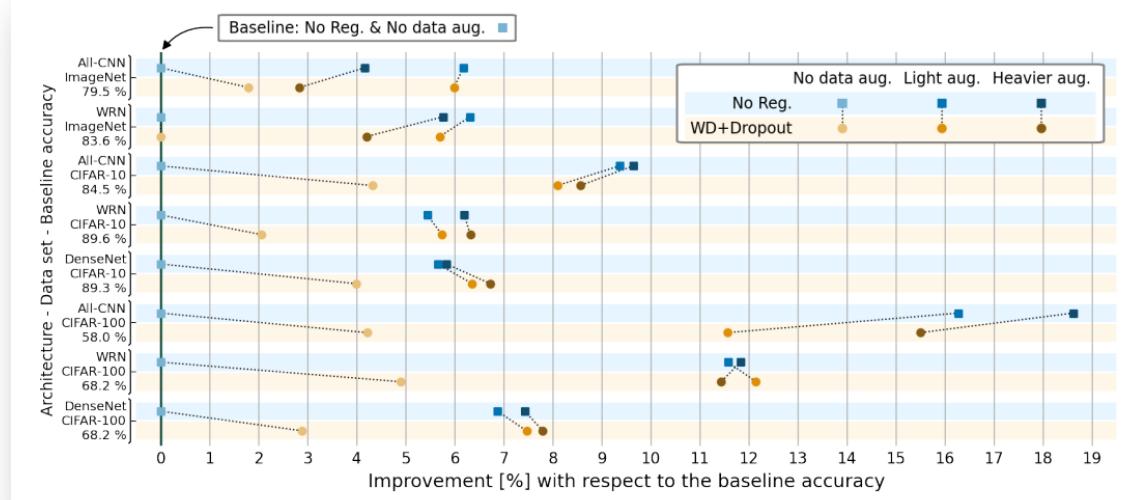
Dropout?

Estudiar dónde conviene aplicarlo.

Data augmentation instead of explicit regularization

Alex Hernandez-Garcia*
Institute of Cognitive Science
University of Osnabrück
Germany
ahernandez@uos.de

Peter König
Institute of Cognitive Science
University of Osnabrück
Germany
pkoenig@uos.de





El entrenamiento

---- • 2. Reducir el overfitting

**Ahora lo queremos bajar...
... pero sin romper todo**

---- • Ordenar qué políticas de data augmentation

Definir operaciones + estrategia tipo RandAugment
(nro. operaciones vs. fuerza)

---- • Weight decay?

Probar algunas tasas

---- • Dropout?

Estudiar dónde conviene aplicarlo.

**Ver mejoras en validación
a costa de pérdida en training**

Forward selection

Un modelo nuevo!

Contribución metodológica al área

¿Cómo lo validamos?

benchmark

protocolo de evaluación
(dataset + métricas)

baselines

modelos para resolver
un problema similar





Slides acá!



----- •
**¡Gracias
por tu atención!**
¿Tenés alguna pregunta?

✉ jiorlando@pladema.exa.unicen.edu.ar





CONICET
UNICEN
Universidad Nacional del Centro
de la Provincia de Buenos Aires

Cómo entrenar bien un baseline:

Experiencias y recomendaciones
desde la aplicación de deep learning
en oftalmología

Dr. José Ignacio Orlando

Grupo Yatiris. Instituto PLADEMA / CONICET / UNICEN.

@ignaciorlando

José Ignacio Orlando

